

موضوع

نیم سراسری اول - تشریحی

موضوع: ۱۳۸۱ ۲۵۱ ۴۰۱

درستی عشق -

سوال ① - این طبقه بندی Bayes  $m$  طبقه داریم. (از جدول بین و طبقه بندی سوال)

$$\hat{\eta}_j = \arg \max_{\eta_j} P(\eta_j) P(x/\eta_j) \quad j=1 \sim m$$

و  $m=3$ ، این هر ۳ بر حسب  $P(\eta_j) = \frac{1}{3}$  است، بنابراین این کار است

$P(x/\eta_j)$  این هر ۳ بر حسب حساب کرده و  $\max$  انتخاب کنیم. از آن صافی در  $j=1, 2, 3$

توزیع هر کدام نرمال است،  $n=2$ ، داریم:  $(x/y \mid \eta_i) \sim N(\mu_i, \Sigma_i)$

$$\Rightarrow P(x/\eta_i, \mu_i, \Sigma_i) = \frac{1}{(2\pi)^{\frac{n}{2}} |\Sigma_i|^{\frac{1}{2}}} \exp\left(-\frac{1}{2} (x-\mu_i)^T \Sigma_i^{-1} (x-\mu_i)\right)$$

$$\mu_1 = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \Sigma_1 = \begin{pmatrix} 0.7 & 0 \\ 0 & 0.7 \end{pmatrix} \Rightarrow |\Sigma_1| = 0.49, \Sigma_1^{-1} = \frac{100}{49} \begin{pmatrix} 0.7 & 0 \\ 0 & 0.7 \end{pmatrix} : i=1$$

$$\mu_2 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \Sigma_2 = \begin{pmatrix} 0.8 & 0.3 \\ 0.3 & 0.2 \end{pmatrix} \Rightarrow |\Sigma_2| = 0.07, \Sigma_2^{-1} = \frac{100}{9} \begin{pmatrix} 0.2 & -0.3 \\ -0.3 & 0.8 \end{pmatrix} : i=2$$

$$\mu_3 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \Sigma_3 = \begin{pmatrix} 0.7 & 0.2 \\ 0.2 & 0.8 \end{pmatrix} \Rightarrow |\Sigma_3| = 0.52, \Sigma_3^{-1} = \frac{100}{52} \begin{pmatrix} 0.8 & -0.2 \\ -0.2 & 0.7 \end{pmatrix} : i=3$$

$$\mu = \begin{pmatrix} 50 \\ 0.5 \end{pmatrix} \quad (\text{given})$$

$$P(x|\Omega_1) = \frac{1}{2\pi \times 0.7} \times \exp\left(-\frac{1}{2} \times \frac{100}{49} (50 \ 0.5) \begin{pmatrix} 0.7 & 0 \\ 0 & 0.7 \end{pmatrix} \begin{pmatrix} 50 \\ 0.5 \end{pmatrix}\right)$$

$$= \frac{1}{1.4\pi} \exp\left(-\frac{50}{49} \times 1750.175\right) \Rightarrow \ln(P_1) = -1787.3$$

$$P(x|\Omega_2) = \frac{1}{0.2\pi \times \sqrt{7}} \exp\left(-\frac{1}{2} \times \frac{100}{9} (49 \ -0.5) \begin{pmatrix} 0.2 & -0.3 \\ -0.3 & 0.8 \end{pmatrix} \begin{pmatrix} 49 \\ -0.5 \end{pmatrix}\right)$$

$$= \frac{1}{0.2\pi \times \sqrt{7}} \exp\left(-\frac{50}{9} \times 495.1\right) \Rightarrow \ln(P_2) = -2751.06$$

$$P(x|\Omega_3) = \frac{1}{0.2\pi \times \sqrt{52}} \exp\left(-\frac{1}{2} \times \frac{100}{52} (49 \ -0.5) \begin{pmatrix} 0.8 & -0.2 \\ -0.2 & 0.7 \end{pmatrix} \begin{pmatrix} 49 \\ -0.5 \end{pmatrix}\right)$$

$$= \frac{1}{0.2\pi \times \sqrt{52}} \exp\left(-\frac{50}{52} \times 1930.78\right) \Rightarrow \ln(P_3) = -1858.03$$

• Case 1  $\mu \in \Omega_1$

$$P(x|\Omega_1) = \frac{1}{1.4\pi} \exp\left(-\frac{50}{49} (0.5 \ 0.5) \begin{pmatrix} 0.7 & 0 \\ 0 & 0.7 \end{pmatrix} \begin{pmatrix} 0.5 \\ 0.5 \end{pmatrix}\right) = \frac{1}{1.4\pi} \exp(-0.357)$$

$$P(x|\Omega_2) = \frac{1}{0.2\pi \sqrt{7}} \exp\left(-\frac{50}{9} (-0.5 \ -0.5) \begin{pmatrix} 0.2 & -0.3 \\ -0.3 & 0.8 \end{pmatrix} \begin{pmatrix} -0.5 \\ -0.5 \end{pmatrix}\right) = \frac{1}{0.2\pi \sqrt{7}} \exp(-0.56)$$

$$P(x|\Omega_3) = \frac{1}{0.2\pi \sqrt{7}} \exp\left(-\frac{50}{52} (-0.5 \ -0.5) \begin{pmatrix} 0.8 & -0.2 \\ -0.2 & 0.7 \end{pmatrix} \begin{pmatrix} -0.5 \\ -0.5 \end{pmatrix}\right) = \frac{1}{0.2\pi \sqrt{7}} \exp(-0.264)$$

•  $x \in \Omega_3$

$\Leftarrow$   $\text{Case 2}$   $\mu \in \Omega_3$   $\Leftarrow$

①

$$\tilde{E}_D(w) = \frac{1}{2} \sum_n \left( w_0 + \sum_i w_i x_{ni} + \sum_i w_i \epsilon_{ni} - y_n \right)^2$$

$$= \frac{1}{2} \sum_n \left( w_0 + \sum_i w_i x_{ni} - y_n \right)^2 + \frac{1}{2} \sum_n \sum_i w_i^2 \epsilon_{ni}^2 + \sum_n \left( \sum_i w_i \epsilon_{ni} \right) \left( w_0 + \sum_i w_i x_{ni} - y_n \right)$$

از عبارت فوق امید ریاضی می‌گیریم (در این خط می‌بینیم که امید ریاضی از جمله اول حذف می‌شود و به صفر می‌رسد)

$$E[\tilde{E}_D(w)] = \underbrace{E_D(w)}_{\text{تیر اول}} + \underbrace{\frac{1}{2} \sum_n \sum_i w_i^2 \sigma^2}_{\text{تیر دوم}} + \underbrace{\sum_n \left( \sum_i w_i E(\epsilon_{ni}) \right) \left( w_0 + \sum_i w_i x_{ni} - y_n \right)}_{\text{تیر سوم}}$$

تیر سوم صفر است و امید ریاضی هم صفر است.

$$= E_D(w) + \frac{N\sigma^2}{2} \sum_i w_i^2 + 0$$

$$\Rightarrow E[\tilde{E}_D(w)] = E_D(w) + \frac{N\sigma^2}{2} \sum_i w_i^2$$



نکته: (۱)

$$\text{class 1: } \ln\left(\frac{P_1}{P_K}\right) = \beta_1^T x$$

$$\text{class 2: } \ln\left(\frac{P_2}{P_K}\right) = \beta_2^T x$$

$$\text{class } k-1: \ln\left(\frac{P_{k-1}}{P_K}\right) = \beta_{k-1}^T x$$

$$\text{class } k: 1 - \sum_{i=1}^{k-1} P_i$$

$$\text{class 1: } P_1 = \frac{e^{\beta_1^T x_i}}{1 + \sum_{i=1}^{k-1} e^{\beta_i^T x_i}}$$

$$\text{class 2: } P_2 = \frac{e^{\beta_2^T x_i}}{1 + \sum_{i=1}^{k-1} e^{\beta_i^T x_i}}$$

$$\text{class } k-1: P_{k-1} = \frac{e^{\beta_{k-1}^T x_i}}{1 + \sum_{i=1}^{k-1} e^{\beta_i^T x_i}}$$

$$\text{class } k: P_k = \frac{1}{1 + \sum_{i=1}^{k-1} e^{\beta_i^T x_i}}$$

اینست اینها را می توانیم به صورت زیر بنویسیم:

$$L(\beta, x) = \sum_{i=1}^N \log(P_i(x_i, \beta_i^T)) = \sum_{i=1}^N \log\left(\frac{e^{\beta_i^T x_i}}{1 + e^{\beta_i^T x_i}}\right)$$

$$\begin{aligned} \frac{\partial}{\partial \beta} L(\beta, x) &= \sum_{i=1}^N \frac{\partial}{\partial \beta} \left[ \beta_i^T x_i - \ln(1 + e^{\beta_i^T x_i}) \right] \\ &= \sum_{i=1}^N x_i - \frac{x_i e^{\beta_i^T x_i}}{1 + e^{\beta_i^T x_i}} = \sum_{i=1}^N x_i (y_i - p_i) \end{aligned}$$

$$\nabla L(\beta, x) = \sum_{i=1}^N x_i (y_i - p_i)$$

سؤال ④ - الف) رگرسیون خطی را فقط بوی یک ویژگی آموزش دهیم.

باید روش را پیدا کنیم که هزینه را  $\min$  کند  
 رابطه مدل:  $y = w_j x_{ij} + \epsilon$

(جمع مربعات رابطه را می‌نویسیم)

$$\rightarrow \min \sum (y_i - w_j x_{ij})^2$$

$$\rightarrow \frac{\partial}{\partial w_j} (\cdot) = 0 \Rightarrow \sum 2 x_{ij} (y_i - w_j x_{ij}) = 0$$

$$\Rightarrow 2 \sum (x_{ij} y_i) - 2 w_j \sum x_{ij}^2 = 0 \Rightarrow w_j = \frac{\sum x_{ij} y_i}{\sum x_{ij}^2}$$

تیم  $x_{ij} y_i$  حاصل ضرب داخلی سؤال ویژگی  $x_{ij}$  و  $y_i$  است و

تیم  $x_{ij}^2$  جمع مربعات سؤال ویژگی  $x_{ij}$  است که ضرب داخلی با خودش است

$$w_j = \frac{x_j^T \cdot y}{x_j^T \cdot x_j}$$

ب) مقادیر سؤال  $x_j$  یعنی متغیرهای ویژگی کل داده است.

دو بردار آموزش داده و ویژگی  $x_j$  و آموزش متغیر  $y_i$  را بر سر هم می‌نویسیم و به این نتیجه می‌رسیم.

• ادامه صفحہ بعدی

۱) آموزش مدل خطی و رگرسیونی (تلفظ)

در این حالت رگرسیون خطی چند متغیره را می بینیم که یک ترکیب خطی از تمام ویژگی ها است.

مدل خطی: 
$$\hat{y} = X \cdot \beta + \epsilon$$
  
 که در آن  $\hat{y}$  پیش بینی،  $X$  ماتریس ویژگی ها،  $\beta$  ضرایب و  $\epsilon$  خطای مدل است.

ما می خواهیم به روش کمترین مربعات (OLS) ضرایب  $\beta$  را پیدا کنیم.

$$X^T \cdot X \cdot \beta = X^T \cdot y$$

۲) آموزش مدل مستقل خطی:

در این حالت یک رگرسیون خطی مستقل را می بینیم. یعنی ویژگی  $x_i$  را از سایر ویژگی ها جدا می کنیم.

مدل مستقل: 
$$\hat{y} = w x_i + \epsilon$$
  
 که در آن  $\hat{y}$  پیش بینی،  $w$  ضرایب و  $\epsilon$  خطای مدل است.

فرمول برای محاسبه ضرایب  $w$ :

$$w = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}$$

این فرمول برای هر یک از ویژگی ها به کار می رود.

چون می خواهیم به روش کمترین مربعات (OLS) ضرایب  $\beta$  را پیدا کنیم، باید به این نکته توجه کنیم:

ماتریس  $X^T \cdot X$  باید معکوس پذیر باشد. اگر این ماتریس معکوس پذیر نباشد، یعنی اگر یکی از ویژگی ها صفر باشد، نمی توانیم ضرایب را پیدا کنیم.



3.1.1.1

$$y = w_j x_{ij} + w_0 + \epsilon$$

↑  
↓  
وزن  
وزن

12

$$\Rightarrow w_j = \arg \min_{w_0, w_j} \left( \sum (y_i - (w_j x_{ij} + w_0))^2 \right)$$

(w<sub>j</sub>):  $\frac{\partial}{\partial w_j} (\cdot) = 0$

$$\sum -2(y_i - (w_j x_{ij} + w_0)) \times (-x_{ij}) = 0$$

$$\Rightarrow \sum (y_i x_{ij} - w_j x_{ij}^2 - w_0 x_{ij}) = 0$$

$$\Rightarrow w_j \sum x_{ij}^2 = \sum y_i x_{ij} - \sum w_0 x_{ij}$$

$$\Rightarrow w_j = \frac{\sum y_i x_{ij} - \sum w_0 x_{ij}}{\sum x_{ij}^2} = \frac{\text{Cov}(x_{ij}, y)}{\text{Var}(x_{ij})} - \frac{w_0 \sum x_{ij}}{\sum x_{ij}^2}$$

(w<sub>0</sub>):  $\frac{\partial}{\partial w_0} (\cdot) = 0$

$$\sum -2(y_i - w_j x_{ij} + w_0) \times (-1) = 0$$

$$\Rightarrow \sum y_i - w_j \sum x_{ij} - \sum w_0 = 0 \Rightarrow w_0 = \frac{\sum y_i}{N} - w_j \frac{\sum x_{ij}}{N}$$

$$\Rightarrow w_0 = E(y) - w_j E(x) \quad \checkmark$$

سوال ۵:  $P(X \geq \alpha) \leq \frac{E(X)}{\alpha}$  (الف) فرض کنید  $0 \leq X$  و  $\alpha$  یک عدد مثبت باشد و  $\alpha$  از میانگین  $E(X)$  بزرگتر باشد.

جواب:  $E(X) = \int_{-\infty}^{\infty} x f(x) dx \xrightarrow{0 \leq x} E(X) = \int_0^{\infty} x f(x) dx$

$$\Rightarrow E(X) = \int_0^{\alpha} x f(x) dx + \int_{\alpha}^{\infty} x f(x) dx \geq \int_{\alpha}^{\infty} x f(x) dx \geq \int_{\alpha}^{\infty} \alpha f(x) dx$$

$$\Rightarrow E(X) \geq \int_{\alpha}^{\infty} \alpha f(x) dx = \alpha \int_{\alpha}^{\infty} f(x) dx = \alpha \Pr(X \geq \alpha)$$

$$\Rightarrow \Pr(X \geq \alpha) \leq \frac{E(X)}{\alpha} \quad \checkmark$$

ب) در مورد مارکوف متغیر تصادفی  $(X)$  برابر  $Y = (Z - \mu)^2$

قرار می دهیم که  $Y$  متغیر تصادفی نامقر است و شرط فرض را برآورده می کند و مقدار  $\alpha$

برابر  $\alpha = \epsilon^2$  قرار می دهیم. خواهیم داشت:

$$\Pr(|Z - \mu| \geq \epsilon) = \Pr((Z - \mu)^2 \geq \epsilon^2) \leq \frac{E((Z - \mu)^2)}{\epsilon^2} = \frac{\sigma^2}{\epsilon^2}$$

$$\Rightarrow \Pr(|Z - \mu| \geq \epsilon) \leq \frac{\sigma^2}{\epsilon^2} \quad \checkmark$$



ج) طبق سائله تعریف شده،  $x_i$  را متغیر تصادفی نقطه ای نام انتخابی می‌کنیم که

از این ربع انتخاب می‌شود اگر داخل دایره بود  $x_i = 1$  و در غیر این صورت  $x_i = 0$

در این صورت پس از انتخاب  $n$  نقطه متوالی، تخمین مقدار  $\pi$  را بصورت زیر بدست می‌آوریم

چون نسبت مساحت دایره به کل مربع  $\frac{\pi}{4}$  باشد.

$$\hat{\pi}(n) = 4 \cdot \frac{\sum_{i=1}^n x_i}{n}$$

احتمال موفقیت هر رهبر  $x_i$  برابر  $\frac{\pi}{4}$  است.

$$E(x_i) = \frac{\pi}{4} \times 1 + (1 - \frac{\pi}{4}) \times 0 = \frac{\pi}{4}$$

$$V(x_i) = \frac{\pi}{4} \times (1 - \frac{\pi}{4})$$

پس از آن  $\hat{\pi}$  دارای تخمین بدون بایاس است و تخمین صحیح می‌باشد:

$$E(\hat{\pi}) = E\left(\frac{4}{n} \sum_{i=1}^n x_i\right) = \frac{4}{n} \sum_{i=1}^n E(x_i) = \pi$$

$$V(\hat{\pi}) = V\left(\frac{4}{n} \sum_{i=1}^n x_i\right) = \frac{16}{n^2} \sum_{i=1}^n V(x_i) = \frac{\pi(4-\pi)}{n}$$

حال فرض کنیم با احتمال حداقل 95٪، خطای تخمین کمتر از  $\delta = 0.01$  باشد.

$$P(|\hat{\pi}(n) - \pi| < \delta) > \epsilon \xrightarrow[\text{جستار معادل}]{} P(|\hat{\pi}(n) - \pi| \geq 0.01) \leq 1 - 0.95$$

یعنی از حسیف داریم:  $0.05 \geq \frac{V(\hat{\pi})}{n^2}$  (در ادامه صفر ده)

$$V(\hat{\pi}) = \frac{\pi(4-\pi)}{n} \quad \text{مطلوب}$$

$$\Rightarrow \frac{\pi(4-\pi)}{n(0.01)^2} \leq 0.05$$

$$\Rightarrow n \geq 5.393532 \times 10^5$$

$$\Rightarrow n \geq 539353$$

سؤال (۶) - الف)

چون  $A$  ماتریس مربعی وارون پذیر است، قدرتی  $A$ ،  $A^{-1}$  و  $A^T$  قدرتی.

$$AA^T \text{ و } A^T A \text{ است. از این حاصل می شود } A^{-1}(A^{-1})^T = (A^T A)^{-1}$$

قدرتی  $A^{-1}$ ،  $A$  قدرتی و  $A$  همنه وار  $\sigma_1$ ،  $\sigma_n$  قدرتی  $A$  و

$$\sigma_n \text{ کمینه آن باشد، } \sigma_{\max}(A) = \frac{\sigma_1}{\sigma_n} \text{ و } \sigma_{\max}(A^{-1}) \text{ و چون } \sigma_1 \geq \sigma_n$$

$$\sigma_{\max}(A^{-1}) \sigma_{\max}(A) \geq 1 \quad \checkmark$$

$$\|A\|_2 \leq \|A\|_F \leq \sqrt{\text{rank}(A)} \|A\|_2 \quad \text{ب)}$$

قسمت اول تساوی  $\|A\|_2 \leq \|A\|_F$  ؟

$$\|A\|_2 = \text{بزرگترین قدرتی } A$$

$$\|A\|_F = \sqrt{\sum_{i,j} |a_{ij}|^2} \text{ و } A \text{ بر روی قدرتی}$$

که  $U$  و  $V$  متعامد و  $\Sigma$  ماتریس قطری از قدرتی  $A = U \Sigma V^T$  : بزرگترین  $A$   $\sigma_1, \dots, \sigma_k$  است که  $\text{rank}(A) = k$  است.

$$\Rightarrow \|A\|_F = \sqrt{\sum_{j=1}^k (\sigma_j)^2} \quad , \quad \|A\|_2 = \sigma_1$$

الاف صفری بعد.



از درستی درست آمده و افق است که  $\sigma_1^2 \leq \sum_{i=1}^k \sigma_i^2$  و  $\sigma_1 \leq \sqrt{\sum_{i=1}^k \sigma_i^2}$

چون در هر صورت راست جمع  $\sigma_1^2$  و تقسیم ناقص بوده است.

$$? \quad \|A\|_F \leq \sqrt{\text{rank}(A) \cdot \|A\|_2^2}$$

درستی قبل دیدیم:  $\|A\|_F \leq \sqrt{\sum_{i=1}^k \sigma_i^2} \leq \sqrt{k} \times \sigma_1 = \sqrt{\text{rank}(A)} \times \|A\|_2$

تقریب  $\|A\|_2$  و  $\sigma_1$  بزرگ است و  $\sigma_1$  بزرگ است و  $\sigma_1$  بزرگ است و  $\sigma_1$  بزرگ است.

$$\|A\|_2 \leq \|A\|_F \leq \sqrt{\text{rank}(A) \cdot \|A\|_2^2} \quad \square$$

مثال ۷: ابتدا رابطه زیر را بسنج Sigmoid،  $\tanh$  نسبت و رابطه

$$\tanh(a) = 2\sigma(2a) - 1, \text{ where: } \sigma(z) = \frac{1}{1+e^{-z}}, \tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$$

$$\begin{aligned} 2\sigma(2a) - 1 &= \frac{2}{1+e^{-2a}} - 1 = \frac{2 - 1 - e^{-2a}}{1+e^{-2a}} \\ &= \frac{1 - e^{-2a}}{1+e^{-2a}} = \frac{e^{-a}(e^a - e^{-a})}{e^{-a}(e^a + e^{-a})} = \frac{e^a - e^{-a}}{e^a + e^{-a}} = \tanh(a) \checkmark \end{aligned}$$

حالا می بینیم که از رابطه فوق می توانیم Sigmoid بسنجیم و برعکس

$$y_j = \frac{x - \mu_j}{s} \quad \text{چون } \mu_j = \tanh(y_j) \text{ پس}$$

$$\boxed{y(x, w)} = w_0 + \sum_{j=1}^n w_j \sigma(2y_j) \quad \sigma(2a) = \frac{(\tanh(a) + 1) \times \frac{1}{2}}{\longrightarrow}$$

$$= w_0 + \sum w_j \left( \frac{\tanh(y_j) + 1}{2} \right)$$

$$= w_0 + \underbrace{\frac{1}{2} \sum_{j=1}^n w_j}_{u_0} + \sum_{j=1}^n \underbrace{\frac{w_j}{2}}_{u_j} \cdot \tanh(y_j)$$

$$= u_0 + \sum_{j=1}^n u_j \tanh(y_j) = \boxed{y(x, u)} \checkmark$$